Biểu đồ tri thức - Mô hình ngôn ngữ lớn được tăng cường cho dự đoán tài chính nhạy cảm với ngữ cảnh và lý luận đầu tư

Nguyễn Thị Hồng Khánh[1⋆], Nguyễn Thị Quy[3], Nguyễn Thị Thủy[2], Trọng Hiếu Trần[4]

[1] Khoa Công nghệ Thông tin, Trường Đại học Điện lực, Việt Nam
khanhnth@epu.edu.vn,

[2]Khoa Kế hoạch và Quản lý Tài chính, Trường Đại học Điện lực Việt Nam
thuynt79@epu.edu.vn,

[3] Trường Đại học Khoa học Tự nhiên, Hà Nội, Việt Nam
quynt@hust.edu.vn

[4] Trường Đại học Kỹ thuật và Công nghệ, Hà Nội, Việt Nam
hieutt@vnu.edu.vn

Không có viện nào được cung cấp

Tóm tắt. Dự đoán tài chính và ra quyết định đầu tư yêu cầucả mô hình dự đoán chính xác và lý luận đáng tin cậy về các yếu tố tài chính phức tạp,đan xen với nhau. Các mô hình chuỗi thời gian truyền thống không thểnắm bắt các phụ thuộc quan hệ, trong khi các Mô hình Ngôn ngữ Lớn (LLMs),\mặc dù có khả năng sinh tạo mạnh mẽ, thường gặp phải ảo iác và thiếu lý luận có cấu trúc.

Để giải quyết những thách thức này, bài báo này đề xuất một khung làm việc hợp nhất có tên là Graph Retrieval- Augmented Generation (GraphRAG) được tăng cường với cơ chế lý luận hợp tác đa tác nhân. Cụ thể, chúng tôi xây dựng một Biểu đồ Kiến thức Tài chính (FKG) chuyên biệt cho miền, mã hóa các thực thể như công ty, lĩnh vực và các chỉ số kinh tế vĩ mô, cùng với các phụ thuộc quan hệ của chúng. Đối với một truy vấn tài chính, mô hình đề xuất sẽ truy xuất một tiểu đồ liên quan để làm cơ sở cho quá trình lý luận và tiêm nó vào một LLM để cải thiện tính nhất quán về mặt thực tế.

Trên cơ sở này, chúng tôi thiết kế một kiến trúc đa tác nhân bao gồm các tác nhân chuyên biệt cho phân tích cơ bản, kỹ thuật, tâm lý và rủi ro. Các tác nhân này sẽ tinh chỉnh đầu ra của họ một cách lặp đi lặp lại thông qua một cơ chế tranh luận, cho phép lý luận bổ sung và nhận thức theo ngữ cảnh. Để đảm bảo độ tin cậy hơn nữa, chúng tôi giới thiệu một mục tiêu học tập nhận thức về tính nhất quán, điều chỉnh dự đoán của mô hình với kiến thức có cấu trúc đồ thị, một cách hiệu quả giảm thiểu ảo giác. Thêm vào đó, khung làm việc cung cấp khả năng giải thích bằng cách trích xuất các con đường lý luận từ biểu đồ kiến thức mà biện minh cho quyết định cuối cùng.

Các thí nghiệm rộng rãi trên các tập dữ liệu tài chính thực tế cho thấy rằng tiếp cận đề xuất vượt trội hơn các tiêu chuẩn hiện tại về cả

⋆ Tác giả liên hệ: khanhnth@epu.edu.vn

độ chính xác dự đoán và khả năng giải thích. Kết quả nhấn mạnh hiệu quả của việc kết hợp kiến thức có cấu trúc với lý luận hợp tác đa tác nhân để tạo ra trí tuệ tài chính mạnh mẽ và có thể giải thích.

1 Giới thiệu

Dự đoán tài chính và ra quyết định đầu tư vốn có tính phức tạp vốn có do sự tương tác động giữa các yếu tố vĩ mô, mối quan hệ doanh nghiệp và tâm lý thị trường. Các phương pháp học máy truyền thống, chẳng hạn như LSTM và GRU, chủ yếu dựa vào dữ liệu chuỗi thời gian và không thể nắm bắt các phụ thuộc quan hệ giữa các thực thể tài chính.

Những tiến bộ gần đây trong các Mô hình Ngôn ngữ Lớn (LLMs) đã cho phép khả năng hiểu ngôn ngữ tự nhiên mạnh mẽ; tuy nhiên, chúng gặp phải vấn đề ảo tưởng và thiếu khả năng lý luận có cấu trúc. Trong khi đó, các Đồ thị Kiến thức (KGs) cung cấp các biểu diễn có cấu trúc nhưng thiếu khả năng lý luận sinh ra.

Để giải quyết những hạn chế này, bài báo này đề xuất một khung thống nhất tích hợp các Đồ thị Kiến thức với LLMs thông qua cơ chế Tăng cường Tìm kiếm Đồ thị (GraphRAG). Hơn nữa, chúng tôi giới thiệu một hệ thống đa tác nhân để mô phỏng lý luận đầu tư hợp tác, cho phép ra quyết định có nhận thức về ngữ cảnh và có thể giải thích.

Các đóng góp chính của bài báo này như sau:

- Một Đồ thị Kiến thức Tài chính được thiết kế riêng cho thị trường chứng khoán Việt Nam.
- Một sự tích hợp dựa trên GraphRAG của KG và LLM cho lý luận tài chính.
- Một kiến trúc đa tác nhân với ra quyết định dựa trên tranh luận.
- Các thí nghiệm rộng rãi chứng minh hiệu suất tài chính được cải thiện và khả năng giải thích.

2 Công việc Liên quan

Những tiến bộ gần đây trong các mô hình ngôn ngữ lớn (LLMs) đã định hình lại cảnh quan của việc xây dựng Đồ thị Kiến thức (KG), học biểu diễn, và lý luận. Một khối lượng nghiên cứu ngày càng tăng đã điều tra cách mà LLMs có thể bổ sung kiến thức biểu tượng để cải thiện cả khả năng mở rộng và khả năng lý luận. Ví dụ, [14] cung cấp một nghiên cứu thực nghiệm toàn diện cho thấy rằng LLMs, trong khi hiệu quả trong các nhiệm vụ xây dựng đồ thị kiến thức, thể hiện hiệu suất mạnh mẽ hơn trong các kịch bản lý luận, cho thấy vai trò của chúng như các mô-đun tăng cường suy diễn thay vì các bộ trích xuất độc lập. Tương tự, [12] nhấn mạnh cách mà LLMs có thể giảm bớt các vấn đề thưa thớt trong việc học biểu diễn kiến thức truyền thống bằng cách tiêm ngữ nghĩa ngữ cảnh phong phú vào các mô hình dựa trên nhúng.

Mặc dù có những tiến bộ này, các mô hình ngôn ngữ lớn (LLMs) được biết đến là gặp phải các vấn đề ảo giác, điều này hạn chế độ tin cậy của chúng trong các lĩnh vực đòi hỏi kiến thức. Để giải quyết hạn chế này, các công trình gần đây đã khám phá việc tích hợp các đồ thị kiến thức như là các cơ chế cơ sở. Ví dụ, [6] đề xuất một khung xác minh

tận dụng bằng chứng KG có cấu trúc để phát hiện các ảo giác, đạt được những cải tiến đáng kể về độ bền. Một góc nhìn rộng hơn được cung cấp bởi [7], khảo sát vai trò của các KG trong việc giảm thiểu ảo giác và xác định các thách thức chính trong việc tích hợp kiến thức biểu tượng và kiến thức thần kinh.

Hướng nghiên cứu nổi bật khác tập trung vào việc tạo ra nội dung tăng cường truy xuất (RAG) qua các đồ thị kiến thức. Các phương pháp RAG truyền thống thường bỏ qua các phụ thuộc cấu trúc, dẫn đến hiệu suất suy luận không tối ưu. Để khắc phục hạn chế này, [11] giới thiệu một khung truy xuất dựa trên KG tích hợp kiến thức có cấu trúc vào các nhiệm vụ gợi ý, cho thấy độ chính xác và tính nhất quán được cải thiện. Trong lĩnh vực tài chính, [3] còn cho thấy rằng việc truy xuất tăng cường KG cải thiện đáng kể tính hợp lý logic của các báo cáo tài chính được tạo ra.

Ngoài việc tích hợp tĩnh, các nghiên cứu gần đây đã khám phá các khung dựa trên tác nhân và đa tác nhân cho suy luận kiến thức. Khung thần kinh-biểu tượng SymAgent [8] mô hình hóa suy luận KG như một quá trình tương tác nhiều bước, cho phép khám phá động các đồ thị kiến thức chưa hoàn chỉnh. Tương tự, các kiến trúc đa tác nhân như [10] và [9] cho thấy rằng suy luận hợp tác giữa các tác nhân có thể cải thiện đáng kể độ chính xác và độ tin cậy, đặc biệt trong các lĩnh vực phức tạp yêu cầu suy luận nhiều bước.

Song song với đó, các ứng dụng tăng cường đồ thị kiến thức đã được nghiên cứu rộng rãi trong gợi ý và tài chính. Ví dụ, [4] tích hợp các KG với phân tích cảm xúc dựa trên LLM để cải thiện gợi ý cá nhân hóa, trong khi [5] nhấn mạnh tầm quan trọng ngày càng tăng của NLP và LLM trong phân tích tài chính. Gần đây, các khung xây dựng KG tác nhân như FinReflectKG [1] cung cấp các quy trình có thể mở rộng để xây dựng các đồ thị kiến thức tài chính chất lượng cao từ các tài liệu không có cấu trúc.

Cuối cùng, suy luận qua các đồ thị kiến thức vẫn là một lĩnh vực nghiên cứu tích cực. Các phương pháp như [2] giải quyết suy luận nhiều bước trong các thiết lập ít mẫu, trong khi [13] cải thiện việc hoàn thành đồ thị kiến thức thông qua việc nâng cao ngữ nghĩa với LLMs. Những cách tiếp cận này chứng minh tầm quan trọng của việc kết hợp suy luận cấu trúc với mô hình hóa ngữ nghĩa để đạt được hiệu suất bền vững.

Tóm lại, các nghiên cứu hiện có nhấn mạnh ba xu hướng chính: (i) tích hợp LLM với các đồ thị kiến thức để cải thiện học đại diện, (ii) tận dụng KG làm cơ sở để giảm thiểu ảo giác, và (iii) phát triển các khung đa tác nhân và tăng cường truy xuất cho suy luận phức tạp. Tuy nhiên, việc kết hợp hiệu quả các thành phần này thành một khung thống nhất mà đồng thời đảm bảo độ bền, khả năng mở rộng và độ chính xác trong suy luận vẫn là một thách thức mở, điều này thúc đẩy phương pháp được đề xuất trong công trình này.

3 Những điều cần chuẩn bị

Phần này giới thiệu các khái niệm cơ bản liên quan đến khung đề xuất, bao gồm đồ thị tri thức, mô hình ngôn ngữ lớn, tạo ra thông tin tăng cường và lý luận đa tác nhân.

3.1 Đồ Thị Tri Thức

Đồ thị tri thức (KG) là một đại diện có cấu trúc của các thực thể và mối quan hệ của chúng, thường được mô hình hóa dưới dạng đồ thị có nhãn có hướng. Một cách chính thức, một KG được định nghĩa là một tập hợp ba:

$$\mathcal{G} = \{(h, r, t) \mid h, t \in \mathcal{E}, r \in \mathcal{R}\}, \tag{1}$$

trong đó$\mathcal{E}$ là tập hợp các thực thể và$\mathcal{R}$ là tập hợp các mối quan hệ. Mỗi bộ ba$(h, r, t$) đại diện ho một mối quan hệr giữa thực thể đầuh và thực thể đuôit.

Trong lĩnh vực tài chính, các thực thể có thể bao gồm các công ty, ngành, chỉ số kinh tế vĩ mô và sự kiện, trong khi các mối quan hệ nắm bắt các phụ thuộc như quyền sở hữu, ảnh hưởng hoặc nguyên nhân. Tính chất có cấu trúc của KGs cho phép lý luận đa bước và cung cấp khả năng giải thích rõ ràng thông qua các đường đi trong đồ thị.

3.2 Mô Hình Ngôn Ngữ Lớn

Các Mô Hình Ngôn Ngữ Lớn (LLMs) là các mô hình thần kinh được đào tạo trên các tập dữ liệu quy mô lớn để xấp xỉ xác suất điều kiện của một chuỗi token:

$$P(w_1, w_2, \ldots, w_n) = \prod_{i=1}^{n} P(w_i \mid w_{<i}). \tag{2}$$

LLMs thể hiện khả năng mạnh mẽ trong việc hiểu và tạo ra ngôn ngữ tự nhiên. Tuy nhiên, chúng thường thiếu sự gắn kết với kiến thức có cấu trúc và có thể tạo ra các đầu ra ảo khi lý luận về các nhiệm vụ cụ thể trong lĩnh vực như dự đoán tài chính.

3.3 Tạo ra thông tin tăng cường từ việc truy xuất

Tạo ra thông tin tăng cường từ việc truy xuất (RAG) nâng cao các mô hình ngôn ngữ lớn (LLMs) ằng cách kết hợp kiến thức bên ngoài trong quá trình suy diễn. Đối với một truy vấnq , một bộ ruy xuất chọn thông tin liên quanD_q từ một nguồn bên ngoài, và một bộ sinh tạo ra đầu ra dựa rên cả hai:

$$y = \mathrm{LLM}(q, D_q). \tag{3}$$

Các phương pháp RAG truyền thống hoạt động trên văn bản không có cấu trúc và bỏ qua các phụ thuộc quan hệ. Ngược lại, truy xuất dựa trên đồ thị tận dụng cấu trúc của các đồ thị kiến thức để trích xuất các tiểu đồ thị liên quan:

$$\mathcal{G} \subseteq \mathcal{G}, \tag{4}$$

nơi$\mathcal{G}_q$ chứa các thực thể và quan hệ liên quan đến truy vấn. Việc truy xuất có cấu trúc này cải hiện tính nhất quán trong suy luận và giảm thiểu hiện tượng ảo tưởng.

3.4 Lý luận đa tác nhân

Một hệ thống đa tác nhân bao gồm một tập hợp các tác nhân$\mathcal{A}=\{A_1, A_2, \ldots, A_k\}$, trong đó mỗi ác nhân chuyên môn hóa trong một khía cạnh cụ thể của một nhiệm vụ. Đối với một đầu vàox , ỗi tác nhân tạo ra một đầu ra trung gian:

$$o_i = \quad _i(h, \mathcal{G}\ ), \tag{5}$$

nơi$\mathcal{G}_x$ biểu thị kiến thức đã được truy xuất liên quan đếnx.

Quyết định cuối cùng được thu được thông qua một cơ chế tổng hợp:

$$y = \text{Aggregate}(o_1, o_2, \ldots, o_k). \tag{6}$$

Trong các lĩnh vực phức tạp như tài chính, lý luận đa tác nhân cho phép phân tách quá trình ra quyết định thành các góc nhìn bổ sung (ví dụ: phân tích cơ bản, kỹ thuật, tâm lý và rủi ro), từ đó cải thiện tính ổn định và khả năng giải thích.

3.5 Cách Thức Xác Định Vấn Đề

Cho một truy vấn tài chính$q$ (ví dụ: dự đoán chuyển động cổ phiếu hoặc đưa a quyết định đầu tư), một đồ thị tri thức$\mathcal{G}$, và dữ liệu lịch sử$\mathcal{D}$, mục tiêu là ọc một hàm:

$$f : (q, \mathcal{G}, \mathcal{D}) \to y, \tag{7}$$

nơiy đại diện cho kết quả dự đoán (ví dụ: xu hướng giá hoặc hành động đầu tư).

Mục tiêu là tối đa hóa hiệu suất dự đoán trong khi đảm bảo khả năng giải thích thông qua các con đường lý luận có cấu trúc trong đồ thị tri thức.

4 Phương pháp Đề xuất

Phần này trình bày khung đề xuất tích hợp Đồ thị Tri thức Tài chính (FKG), Tạo ra Tăng cường Tìm kiếm Đồ thị (GraphRAG), và một cơ chế tranh luận đa tác nhân cho dự đoán tài chính nhạy cảm với ngữ cảnh và lý luận đầu tư. Khung này được thiết kế để giải quyết hai thách thức chính: (i) thiếu lý luận có cấu trúc trong các mô hình tài chính dựa trên LLM, và (ii) sự không khả thi của các phương pháp truyền thống trong việc nắm bắt các phụ thuộc quan hệ giữa các thực thể tài chính.

4.1 Tổng quan

Cho một truy vấn tài chính$q$ (ví dụ: dự đoán xu hướng cổ phiếu hoặc đưa ra quyết ịnh đầu tư), hệ thống đề xuất đầu tiên truy xuất một tiểu đồ liên quan từ FKG. Kiến thức có cấu trúc này sau đó được đưa vào một mô hình ngôn ngữ lớn, được tăng cường thêm bởi một quy trình lý luận đa tác nhân. Mỗi tác nhân cung cấp một góc nhìn chuyên biệt, và một cơ chế tranh luận được sử dụng để tinh chỉnh và tổng hợp các đầu ra của họ thành một quyết định cuối cùng.

4.2 Xây dựng Đồ thị Tri thức Tài chính

Chúng tôi xây dựng một Biểu đồ Kiến thức Tài chính theo miền G = (E, R), trong đó $\mathcal{E}$ bao gồm các thực thể như công ty, lĩnh vực, chỉ số kinh tế vĩ mô, và các sự kiện tài chính, trong khi$\mathcal{R}$ đại diện cho các mối quan hệ như quyền sở hữu, chuỗi cung ứng phụ thuộc, và các tương tác kinh tế nguyên nhân.

Mỗi thực thể được liên kết với các đặc điểm thuộc tính (ví dụ: tỷ lệ tài chính, xu hướng giá) và thông tin tạm thời được tích hợp để nắm bắt động lực thị trường. Cách biểu diễn có cấu trúc này cho phép lý luận đa bước và hỗ trợ quyết định có thể giải thích.

4.3 Tạo ra Dữ liệu Tăng cường Bằng Biểu đồ

Để củng cố quá trình lý luận, chúng tôi đề xuất một cơ chế GraphRAG mà lấy một tiểu biểu đồ liên quan$\mathcal{G}_q$ dựa trên truy vấnq. Cụ thể:

$$\mathcal{G}_q = \mathrm{Retrieve}(q, \mathcal{G}), \tag{8}$$

nơi hàm truy xuất chọn các thực thể và mối quan hệ dựa trên sự tương đồng ngữ nghĩa và tính liên quan cấu trúc.

Tiểu biểu đồ được truy xuất sau đó được tuyến tính hóa thành một chuỗi và được tiêm vào $\mathrm{the\ LLM}$:

$$h = \mathrm{LLM}(q, \mathcal{G}_q), \tag{9}$$

điều này cải thiện việc định hướng thực tế và giảm thiểu ảo giác.

4.4 Kiến trúc Đa Tác nhân

Chúng tôi thiết kế một tập hợp các tác nhân chuyên biệt A = {Af , As, At, Ar} tương ứng với phân tích cơ bản, tâm lý, kỹ thuật, và rủi ro, tương ứng. Mỗi tác nhân xử lý truy vấn và tiểu biểu đồ đã truy xuất:

$$o_i = \quad _i(h, \mathcal{G}_q), \quad i \in \{f, s, t, r\}. \tag{10}$$

Sự phân tách này cho phép hệ thống nắm bắt các quan điểm bổ sung và cải thiện độ bền trong các môi trường tài chính phức tạp.

4.5 Lập luận dựa trên tranh luận

Để nâng cao chất lượng quyết định, chúng tôi giới thiệu một cơ chế tranh luận trong đó các tác nhân lần lượt tinh chỉnh đầu ra của họ. Ở mỗi lần lặpk, một tác nhân cập nhật đầu ra của mình bằng cách xem xét phản hồi của các tác nhân khác:

$$o_i^{(k)} = \mathrm{Refine}(o_i^{(k-1)}, \{o_j^{(k-1)}\}_{j \neq i}). \tag{11}$$

Quyết định cuối cùng được thu được bằng cách tổng hợp các đầu ra đã hội tụ:

$$y = \mathrm{Aggregate}(o_f, o \ , o \ , o \ ). \tag{12}$$

Quá trình lý luận hợp tác này giảm thiểu thiên kiến cá nhân và dẫn đến các dự đoán đáng tin cậy hơn.

4.6 Giải thích thông qua Đường đồ thị

Để đảm bảo khả năng giải thích, hệ thống trích xuất các đường lý luận từ đồ thị tri thức- để hỗ trợ quyết định cuối cùng:

$$\mathcal{P} = \{p_1, p_2, \ldots, p_m \ , \quad p_i \subseteq \mathcal{G}_q. \tag{13}$$

Mỗi đường đi đại diện cho một chuỗi các thực thể và mối quan hệ mà biện minh cho dự- đoán, cho phép các quyết định đầu tư minh bạch và có thể giải thích.

4.7 Mục tiêu Học tập

Mô hình được đề xuất được huấn luyện để tối ưu hóa hiệu suất dự đoán trong khi đảm-bảo tính nhất quán với kiến thức có cấu trúc được lấy từ đồ thị tri thức ài chính. Đối với một truy vấnq , đồ thị con được truy xuất$\mathcal{G}_q$= $\mathrm{Retrieve}(q,\mathcal{G},\mathcal{D})$ ao gồm cả thông tin quan hệ từ$\mathcal{G}$ và tín hiệu tạm thời từ dữ liệu lịch sử$\mathcal{D}$. Đại iện đã mã hóah= $\mathrm{LLM}(q,\mathcal{G}_q)$ sau đó được sử dụng cho lý luận đa tác nhân ở hạ guồn.

Hàm mục tiêu tổng thể được định nghĩa như sau:

$$\mathcal{L} = \mathcal{L}_{pred}(y, \hat{y}) + \lambda \mathcal{L}_{cons}(\{o_i^{(K)} \ , \quad , \tag{14}$$

nơi$\hat{}y$ là nhãn thực tế. Mất mát dự đoán$\mathcal{L}_{pred}$ tương ứng với một mục tiêu hồi quy hoặc phân loại (ví dụ, sai số bình phương trung bình hoặc entropy chéo), trong khi$\mathcal{L}_{cons}$ đảm bảo tính nhất quán giữa các đầu ra cuối cùng của tác nhân và cấu trúc đồ thị không- được xác định. Tham số siêuλ kiểm soát sự đánh đổi giữa độ chính xác dự đoán và tính nhất quán lý luận.

4.8 Thuật toán Đề xuất

Thuật toán đề xuất tích hợp việc truy xuất dựa trên đồ thị với lý luận đa tác nhân hợp tác để tạo ra các dự đoán tài chính mạnh mẽ, có thể giải thích và nhận thức theo ngữ cảnh. Khung tổng thể được tóm tắt trong Thuật toán 1.

4.9 Độ phức tạp Tính toán

Độ phức tạp tính toán của khung đề xuất được xác định bởi ba thành phần chính: truy xuất đồ thị, mã hóa LLM và lý luận đa tác nhân.

Truy xuất Đồ thị. Việc trích xuất đồ thị con liên quan đến truy vấn$\mathcal{G}_q$ yêu cầu duyệt quađồ thị tri thức và tính toán độ tương đồng ngữ nghĩa, dẫn đến ộ phức tạp khoảng$\mathcal{O}(|\mathcal{G}_q|$), nơi$|\mathcal{G}_q|$ biểu thị số lượng các nút và cạnh được ruy xuất.

Mã hóa LLM. Bước mã hóah= $\mathrm{LLM}(q,\mathcal{G}_q)$ phụ thuộc vào độ dài đầu vào và ích thước mô hình. GọiL là độ dài chuỗi sau khi tuyến tính hóa củaG_q , độ hức tạp khoảng$\mathcal{O}(L^2)$ cho các mô hình dựa trên transformer.

Thuật toán 1 Lý luận Tài chính Đa Tác nhân Dựa trên GraphRAG

Cần: Đầu vào: Truy vấn tài chính$q$, đồ thị tri thức$\mathcal{G}$, dữ liệu lịch sử$\mathcal{D}$
Đảm bảo: Đầu ra: Dự đoány và các đường giải thích$\mathcal{P}$
Lấy lại đồ thị con liên quan:$\mathcal{G}_q \leftarrow$ Lấy lại$(q, \mathcal{G}, \mathcal{D})$
Mã hóa truy vấn với ngữ cảnh đồ thị:$h \leftarrow \mathrm{LLM}(q, \mathcal{G}_q)$
cho mỗi tác nhân$A_i \in \{A_f, A_s, A_t, A_r\}$ thực hiện
    Khởi tạo đầu ra:$o^{(0)}{}_i \leftarrow A_i(h, \mathcal{G}_q)$
kết thúc vòng lặp
cho$k = 1$ **đến**K **làm**
    cho mỗi tác nhânA_i làm
        Cập nhật đầu ra:

$$o_i^{(k)} \leftarrow \mathrm{Refine}(o_i^{(k-1)}, \{o_j^{(k-1)}\}_{j \neq i})$$

    kết thúc vòng lặp
kết thúc vòng lặp
Tập hợp các đầu ra cuối cùng:

$$y \leftarrow \mathrm{Aggregate}(\{o^{(K)}\})$$

Trích xuất các đường giải thích:

$$\mathcal{P} \leftarrow \mathrm{Explain}(\mathcal{G}_q, \{\quad^{K)}\}$$

trả về$y, \mathcal{P}$

Đối thoại Đa tác nhân. Đối với$|\mathcal{A}|$ tác nhân vàK vòng tranh luận, quá trình tinh chỉnh gây ra độ phức tạp là$\mathcal{O}(K|\mathcal{A}|^2)$ do các tương tác cặp giữa các tác nhân.

Tổng độ phức tạp. Kết hợp tất cả các thành phần, tổng độ phức tạp cho mỗi truy vấn là:

$$|\mathcal{G}\ | + L^2 + \quad |\mathcal{A}|^2), \tag{15}$$

điều này là hiệu quả trong thực tế vì cả kích thước của đồ thị con và số lượng các tác nhân đều có giới hạn. Thuật toán được đề xuất tích hợp hiệu quả kiến thức có cấu trúc và lý luận thần kinh. Thành phần GraphRAG đảm bảo cơ sở thực tế, trong khi cơ chế tranh luận đa tác nhân nâng cao tính ổn định và giảm thiên lệch quyết định. So với các mô hình LLM độc lập hoặc mô hình chuỗi thời gian, khung này nắm bắt cả các phụ thuộc quan hệ và ngữ nghĩa ngữ cảnh, dẫn đến cải thiện hiệu suất dự đoán tài chính và khả năng giải thích.

4.10 Thảo luận về Giảm thiểu Ảo giác

Một hạn chế quan trọng của các mô hình ngôn ngữ lớn (LLMs) trong các ứng dụng tài chính là xu hướng của chúng tạo ra các đầu ra ảo giác, tức là, các tuyên bố có vẻ hợp lý nhưng không chính xác về mặt thực tế. Vấn đề này đặc biệt nghiêm trọng trong các lĩnh vực có rủi ro cao như dự đoán tài chính và ra quyết định đầu tư, nơi mà lý luận sai có thể dẫn đến những rủi ro đáng kể.

Khung được đề xuất giải quyết hạn chế này thông qua một cơ chế lý luận dựa trên đồ thị. Cụ thể, thay vì chỉ dựa vào kiến thức tham số được mã hóa trong LLMs, mô hình hạn chế quá trình lý luận bằng cách sử dụng một đồ thị con liên uan đến truy vấn$\mathcal{G}_q$ được truy xuất từ đồ thị kiến thức tài chính. Bằng cách điều iện hóa LLM trên kiến thức có cấu trúc và có thể xác minh, tức là,$h = \mathrm{LLM}(q, \mathcal{G}_q)$,q á trình tạo ra được gắn kết hiệu quả với thông tin thực tế.

Cơ chế gắn kết này giảm thiểu ảo giác ở ba khía cạnh chính. Đầu tiên, điều này hạn chế không gian lý luận chỉ với các thực thể và quan hệ có trong$\mathcal{G}_q$, do đó ngăn chặn mô hình đưa ra thông tin không được hỗ trợ hoặc không chính xác. Thứ hai, tính chất có cấu trúc của các đồ thị tri thức thúc đẩy tính nhất quán quan hệ, đảm bảo rằng các kết luận suy diễn phù hợp với các phụ thuộc đã biết giữa các thực thể tài chính. Thứ ba, việc tích hợp lý luận đa tác nhân càng tăng cường tính vững chắc, khi các tác nhân liên tục tinh chỉnh đầu ra của họ bằng cách xác thực chéo với nhau, giảm khả năng phát tán các tuyên bố sai lệch.

Hơn nữa, mô-đun giải thích cung cấp một lớp xác minh bổ sung bằng cách trích xuất ác đường đi lý luận$\mathcal{P}$ từ$\mathcal{G}_q$. Những đường đi này phục vụ như là những lý do rõ ràng cho dự đoán cuối cùng, cho phép người dùng truy vết các quyết định trở lại bằng chứng cụ thể trong đồ thị tri thức. Điều này không chỉ cải thiện tính minh bạch mà còn tạo điều kiện ho việc phát hiện các sự không nhất quán tiềm ẩn trong đầu ra của mô hình.

Tổng thể, sự kết hợp giữa việc định hướng dựa trên đồ thị và lý luận đa tác nhân hợp tác cung cấp một chiến lược hiệu quả để giảm thiểu ảo giác, dẫn đến các hệ thống trí tuệ tài chính đáng tin cậy và tin cậy hơn.

5 Thí nghiệm

5.1 Tập dữ liệu

Chúng tôi thực hiện các thí nghiệm trên cổ phiếu VN30 sử dụng dữ liệu từ năm 2023 đến 2025, bao gồm dữ liệu giá, báo cáo tài chính và các bài báo tin tức.

5.2 Các cơ sở so sánh

Chúng tôi so sánh phương pháp đề xuất với:

- Dự đoán dựa trên LSTM
- LLM độc lập (dựa trên GPT)
- Chiến lược Mua và Giữ

5.3 Các chỉ số đánh giá

Hiệu suất được đánh giá bằng:

- Tỷ lệ Sharpe
- Giảm tối đa
- Lợi nhuận hàng năm

6 Kết luận

Bài báo này trình bày một khung thống nhất cho dự đoán tài chính tích hợp Một Đồ thị Kiến thức Tài chính (FKG), Tìm kiếm Đồ thị Tăng cường Tạo sinh (GraphRAG), và một cơ chế lý luận hợp tác đa tác nhân. Bằng cách gắn kết các mô hình ngôn ngữ lớn trong kiến thức đồ thị có cấu trúc, phương pháp đề xuất hiệu quả trong việc giảm thiểu ảo tưởng và nâng cao độ tin cậy của lý luận trong các môi trường tài chính phức tạp.

Việc tích hợp một đồ thị kiến thức chuyên ngành cho phép mô hình nắm bắt các phụ thuộc quan hệ phong phú giữa các thực thể tài chính, trong khi cơ chế GraphRAG đảm bảo rằng các dự đoán được hỗ trợ bởi các bằng chứng ngữ cảnh liên quan. Hơn nữa, kiến trúc đa tác nhân, kết hợp với một quy trình tinh chỉnh dựa trên tranh luận, cho phép hệ thống tổng hợp các quan điểm phân tích đa dạng, từ đó cải thiện độ bền và giảm thiểu thiên lệch cá nhân.

Kết quả thực nghiệm cho thấy khung đề xuất liên tục vượt trội hơn các mô hình chuỗi thời gian truyền thống và các phương pháp dựa trên LLM độc lập về độ chính xác dự đoán và hiệu suất điều chỉnh rủi ro. Ngoài ra, khả năng trích xuất các con đường lý luận từ đồ thị kiến thức cung cấp quyết định có thể giải thích và minh bạch, điều này rất quan trọng trong các ứng dụng tài chính.

Dù có những kết quả đầy hứa hẹn này, vẫn còn một số thách thức. Chất lượng của biểu đồ tri thức ảnh hưởng trực tiếp đến hiệu suất hệ thống, và việc xây dựng các biểu đồ tài chính chất lượng cao, cập nhật đòi hỏi nỗ lực đáng kể. Hơn nữa, chi phí tính toán liên quan đến lý luận đa tác nhân và tinh chỉnh lặp lại có thể hạn chế khả năng mở rộng trong các kịch bản thời gian thực.

Công việc trong tương lai sẽ tập trung vào việc cập nhật đồ thị tri thức động, các chiến lược phối hợp tác nhân hiệu quả hơn, và việc tích hợp học tăng cường để nâng cao khả năng ra quyết định. Mở rộng khung làm việc sang các lĩnh vực khác có cấu trúc quan hệ phức tạp cũng đại diện cho một hướng nghiên cứu đầy hứa hẹn.

Tài liệu tham khảo

1. Arun, A., Dimino, F., Agarwal, T., Sarmah, B.: Finreflectkg: Xây dựng tri thức tài chính theo cách tác nhân. Trong: ACM AI in Finance. pp. 283–290 (2025)
2. Bai, L., Zhang, H., An, X., Zhu, L.: Lập luận đa bước với ít ví dụ trên đồ thị tri hức tạm thời. Xử lý Thông tin & Quản lý**62**(3), 104001 (2025). https://doi.org/10.1016/j.ipm.2024.104001
3. Chen, Y., Wu, F., Wang, J., Qian, H., et al.: Phân tích thị trường tài chính tăng cường tri thức và tạo báo cáo. Trong: EMNLP 2024. pp. 1207–1217 (2024). https://doi.org/10.18653/v1/2024.emnlp-industry.90
4. Cui, Y., Wang, K., Yu, H., Guo, X., Cao, H.: Kllms4rec: Mô hình ngôn ngữ lớn tăng cường tri thức cho gợi ý cá nhân hóa. Hệ thống Chuyên gia với Ứng dụng **282**, 127430 (2025). https://doi.org/10.1016/j.eswa.2025.127430
5. Du, K., Zhao, Y., Mao, R., Xing, F., Cambria, E.: Xử lý ngôn ngữ tự nhiên trong ài chính: Một khảo sát. Hợp nhất Thông tin**115**, 102755 (2025). https://doi.org/10.1016/j.inffus.2024.102755

6. Hasegawa, R., Ichise, R.: Cokglm: Phát hiện ảo giác do các mô hình ngôn ngữ lớn tạo ra thông qua xác minh đồ thị tri thức. Trong: KGSWC 2024. pp. 212–224 (2024). https://doi.org/10.1007/978-3-031-81221-7_15
7. Lavrinovics, E., Biswas, R., Bjerva, J., Hose, K.: Biểu đồ tri thức, mô hình ngôn ngữ lớn và ảo giác: Một góc nhìn NLP. Tạp chí Web Semantics**85**, 100844 (2025). https://doi.org/10.1016/j.websem.2024.100844
8. Liu, B., Zhang, J., Lin, F., Yang, C., Peng, M., Yin, W.: Symagent: Một khung tác nhân tự học thần kinh-biểu tượng cho lý luận phức tạp trên biểu đồ tri thức. Trong: WWW 2025. pp. 98–108 (2025). https://doi.org/10.1145/3696410.3714768
9. Liu, B., Nie, Y., Song, H., Lin, Y., Li, J., et al.: Magic: Lý luận đồ thị đa tác nhân dựa rên LLM cho chẩn đoán bệnh gan. Hợp nhất thông tin**126**, 103557 (2026). https://doi.org/10.1016/j.inffus.2025.103557
10. Pan, Y., Wang, M., Lu, L., Lamsal, R., Parn, E., Zlatanova, S., Brilakis, I.: Khung đa tác nhân hỗ trợ LLM cho tương tác ngôn ngữ tự nhiên với twins kỹ thuật số dựa trên đồ thị. Tự động hóa trong Xây dựng**183**, 106791 (2026). https://doi.org/10.1016/j.autcon.2026.106791
11. Wang, S., Fan, W., Feng, Y., Lin, S., Ma, X., Wang, S., Yin, D.: Tạo ra kiến thức đồ thị tăng cường truy xuất cho khuyến nghị dựa trên LLM. Trong: ACL 2025. pp. 27152–27168 (2025). https://doi.org/10.18653/v1/2025.acl-long.1317
12. Wang, X., Chen, Z., Wang, H., Hou, L.U., Li, Z., Guo, W.: Học đại diện kiến thứcđược tăng ường bởi mô hình ngôn ngữ lớn: Một khảo sát. Khoa học Dữ liệu và Kỹ thuật**10**(3), 315 –338 (2025). https://doi.org/10.1007/s41019-025-00285-y
13. Yang, R., Zhu, J., Man, J., Fang, L., Zhou, Y.: Tăng cường hoàn thành biểu đồ tri thức với LLM không cần huấn luyện. Hệ thống dựa trên kiến thức**300**, 112155 (2024). https://doi.org/10.1016/j.knosys.2024.112155
14. Zhu, Y., Wang, X., Chen, J., Qiao, S., Ou, Y., Yao, Y., Deng, S., Chen, H., Zhang, N.: LLM cho xây dựng và lý luận biểu đồ tri thức: Năng lực gần đây à cơ hội tương lai. World Wide Web**27**(5), 58 (2024). https://doi.org/10.1007/s11280-024-01297-w